

GTA / UFRJ
GRUPO DE TELEINFORMÁTICA E AUTOMAÇÃO

Politécnica UFRJ

COPPE UFRJ

INTEGRAÇÃO DE SAÍDAS ANTECIPADAS EM RAMOS ESPECIALIZADOS POR CONTEXTO PARA DETECÇÃO DE OBJETOS

Pedro Cintra Silveira, Daniel Sadoc Menasche e Miguel Elias M. Campista

Realizado com recursos do CNPq, CAPES, FAPERJ e FAPESP

Poli – Depto. de Eng. Eletrônica e de Computação
COPPE – Programa de Engenharia Elétrica
Universidade Federal do Rio de Janeiro

Roteiro

1. *Motivação*
2. *Saídas Antecipadas*
3. *Materiais*
4. *Arquiteturas de estudo*
5. *Metodologia*
6. *Resultados*
7. *Conclusão e Trabalhos Futuros*



Motivação

Identificação de objetos em ambientes reais

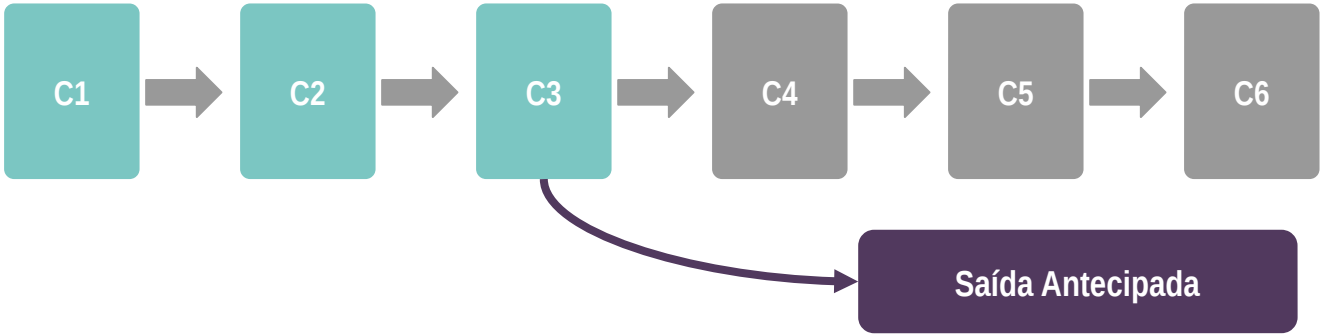
- Problema
  - Cada imagem pode conter vários objetos, escalas e oclusões
- Restrição
  - Latência, energia e memória limitam sistemas embarcados
- Hipótese
  - Imagens simples podem exigir menos processamento

A mesma tarefa de detecção não exige o mesmo custo em todas as cenas.



Fonte: Microsoft COCO, Lin et al.

Saídas Antecipadas



- Predição parcial
  - Imagens são inferidas antes do fim da rede
- Cálculo da confiança
- Decisão pelo limiar τ
  - Confiança ≥ τ: aceita a saída; confiança < τ: continua até a saída final

Materiais

Dataset COCO 2017

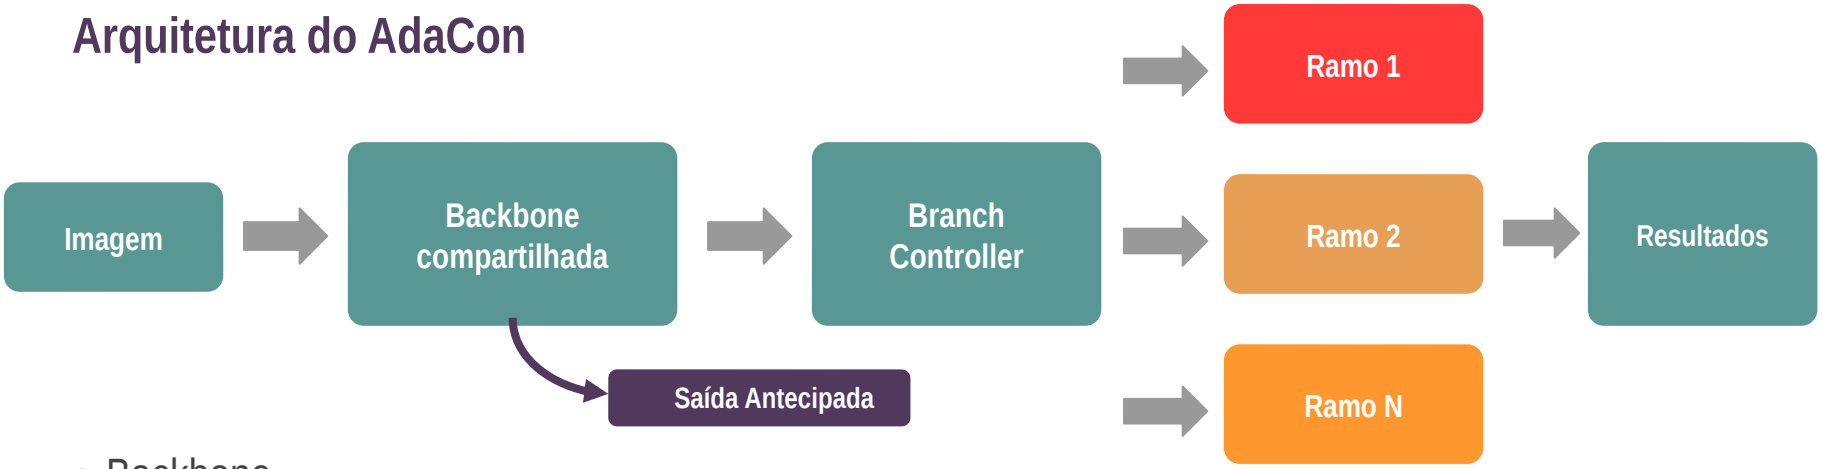
- Origem
  - Microsoft COCO, base pública de detecção de objetos
- Categorias
  - 80 classes de diferentes tipos
- Imagens separadas em:
  - Treino (113.287 imagens)
  - Calibração (5.000 imagens)
  - Validação (5.000 imagens)
- Entrada
  - 416 × 416 pixels



Fonte: Microsoft COCO, Lin et al.

Arquiteturas de estudo

Arquitetura do AdaCon



- Backbone
  - 75 camadas
  - Extraem características das imagens (bordas, formas, texturas)
- Branch Controller
  - Decide quais dos ramos especializados vão ser usados
- Ramos (Branchs)
  - Sub-redes especializadas em classes agrupadas por coocorrência espacial

Arquiteturas de estudo

Configurações 2B, 3B e 4B

Configuração	Número de ramos	Classes de imagens por ramo	Separação por ramo
2B	2	49 e 47	Ambiente Externo / Ambiente Interno
3B	3	40, 25 e 47	Animais e Esporte / Rua / Ambiente Interno
4B	4	40, 25, 23 e 40	Animais e Esporte / Rua / Sala / Cozinha

- Como os grupos são formados
  - AdaCon agrupa classes que aparecem juntas na mesma cena
- Efeito esperado
  - Mais ramos reduzem canais ativos, mas aumentam a fragmentação entre grupos

Metodologia

Passo a passo experimental

1. *Treinamento do AdaCon com o COCO 2017*
2. *Comparação das configurações-base (2B, 3B e 4B)*
3. *Treinamento das saídas antecipadas em diferentes posições*
4. *Escolha da camada da saída antecipada*
5. *Avaliação com diferentes critérios de saída*
6. *Comparação do AdaCon x AdaCon + EE*



Metodologia

Configurações usadas

O que varia	Opções avaliadas
Ramos	2B, 3B e 4B
Camada da saída no Backbone	49, 52, 55, 58 e 61
Modo de detecção	Média, Média Ponderada, Mediana e Mínimo
Limiar τ (threshold)	0,00 a 1,00, passo 0,05



Metodologia

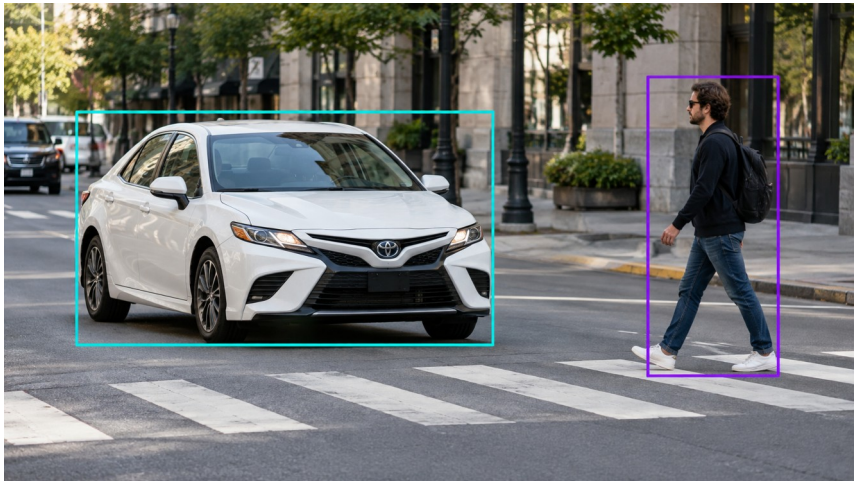
Métricas Avaliadas

COCO AP (AP50:95)

- Qualidade da detecção
  - Classe correta e caixa bem localizada
  - IoU de 0,50 a 0,95, em passos de 0,05
  - Maior valor indica melhor resultado

GMAC por imagem

- Custo computacional por imagem
  - GMAC = bilhões de operações MAC
  - Medido na rota realmente executada
  - Menor valor indica menor custo



Resultados

AdaCon sem saída antecipada

Configuração	COCO AP	GMAC	AP / GMAC
2B	**0,2546**	**28,039**	**0,009081**
3B	0,2331	27,169	0,008578
4B	0,2268	26,735	0,008485

Configuração 2B escolhida como base



Resultados

Qual camada do Backbone usar para saída antecipada?

Camada	COCO AP	GMAC da rota	AP / GMAC
49	0,0968	17,124	0,0056
52	0,1080	18,016	0,0059
55	0,1204	18,851	0,0064
58	**0,1333**	**19,547**	**0,0068**
61	0,1426	21,713	0,0066

Camada 58 escolhida como vencedora

Resultados

Efeito do limiar τ

τ	COCO AP	GMAC	% EE	AP preservado	AP/GMAC
0,20	0,2049	23,221	64,70%	78,16%	0,008826
0,30	0,2385	25,822	31,88%	90,96%	0,009236
0,35	0,2498	26,713	20,68%	95,27%	0,009352
0,40	**0,2550**	**27,240**	**14,08%**	**97,24%**	**0,009360**
0,45	0,2585	27,635	9,14%	98,60%	0,009355
0,50	0,2601	27,830	6,70%	99,19%	0,009346

Média Ponderada · 2B · camada 58

Resultados

Modos de classificação da saída

Método	τ	COCO AP	GMAC	% EE
Média	0,40	0,2565	27,447	11,50%
Média Ponderada	**0,40**	**0,2550**	**27,240**	**14,08%**
Mediana	0,35	0,2532	27,235	14,16%
Mínimo	0,25	0,2572	27,633	9,18%

Escolha final: Média Ponderada com τ = 0,40. AP preservado: 97,24%.

Resultados

AdaCon x AdaCon + EE

Configuração	COCO AP	GMAC	% EE	AP preservado	Redução de GMAC	AP / GMAC
AdaCon 2B	0,2546	28,039	0,00%	100,00%	0,00%	0,009080
AdaCon 2B + EE	**0,2491**	**27,187**	**14,00%**	**97,83%**	**3,04%**	**0,009162**

- Trade-off entre acurácia e custo
- Saída antecipada melhora a relação AP / GMAC



Conclusão e Trabalhos Futuros

Conclusões

- Um possível trade-off de custo x acurácia.
- 14% de imagens sendo inferidas mais cedo.

Trabalhos Futuros

- Avaliar saídas em diferentes camadas.
- Testar novos métodos de decisão.
- Analisar o efeito por classe, escala e quantidade de objetos.



Referências

- NESEEM, M.; REDA, S. “AdaCon: Adaptive Context−Aware Object Detection for Resource−Constrained Embedded Devices.” In: Proc. ICCAD, 2021. pp. 1−9.

- REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. “You Only Look Once: Unified, Real−Time Object Detection.” In: Proc. CVPR, 2016. pp. 779−788.

- TEERAPITTAYANON, S.; MCDANEL, B.; KUNG, H. T. “BranchyNet: Fast Inference via Early Exiting from Deep Neural Networks.” In: Proc. ICPR, 2016. pp. 2464−2469.

